Quiz 12-2

- Someone proposes $h(key) = key$ ("no collisions for distinct keys, perfect!").
- What's wrong?
- What two competing goals?
- What if keys are strings?

힌트 보기

개념 정리 · 해시 함수의 두 경쟁 목표

- ① 계산이 **빨라야** 한다 ↔ ② 키를 테이블 전체에 **고르게 분산**해 충돌을 줄여야 한다.
- 해시 함수의 출력은 **테이블 인덱스**다. 출력 범위 = 테이블 크기.

강의 슬라이드 Ch12 p15 Quiz

정답 보기

풀이

① **문제점.** 키 값 자체를 인덱스로 사용하는 $h(key) = key$는 가능한 키의 인덱스 범위를 수용할 만큼 큰 테이블을 요구한다. 특히 키가 0부터 $M-1$까지의 정수라면 M칸이 필요하므로, 실제 저장된 키가 적을 때 공간 낭비가 심하다.

> 충돌은 없지만 10억 칸 낭비 문제(Quiz 12-1)로 정확히 돌아간다.

두 목표의 긴장. 해시 함수는 빠르게 계산되면서 키를 테이블 전체에 고르게 분산해 충돌을 줄여야 한다. 테이블 크기가 m일 때 가능한 키가 m개보다 많으면 모든 가능한 키를 충돌 없이 매핑할 수 없지만, 실제 저장된 키들 사이에 반드시 충돌이 발생하는 것은 아니다.

> 따라서 좋은 해시 함수는 계산 비용을 낮추면서 제한된 테이블 공간 안에서 키를 가능한 한 균일하게 분산하도록 설계한다.

문자열 키의 경우. $h(key) = key$는 문자열을 그대로 반환하므로 정수 인덱스를 요구하는 해시 테이블에 사용할 수 없다.

문자열의 각 문자를 정수 코드로 해석하고 이를 조합해 테이블 범위 0부터 $m-1$까지의 정수 인덱스를 계산하는 해시 함수가 필요하다. 예를 들어 문자 코드의 다항식 누적 계산과 모듈러 연산을 이용할 수 있으며, 별도의 인코딩 단계 없이 문자열로부터 직접 해시 인덱스를 계산해도 된다.

최종 답 **키 공간만큼 큰 테이블이 필요해 무의미. 목표는 빠른 계산 ↔ 고른 분산의 절충**

한 줄 정리 · 직접 주소 지정 $h(key) = key$은 키 값 자체를 인덱스로 사용하므로 큰 인덱스 범위가 필요해 메모리가 낭비될 수 있다. 일반적인 해시 함수는 큰 키 공간을 제한된 테이블 인덱스 범위로 매핑하므로 서로 다른 키가 충돌할 가능성이 있다. 다만 실제 저장할 키 집합에 대해서는 perfect hashing으로 작은 공간에서도 충돌을 없앨 수 있으므로, 충돌이 없으면 반드시 전체 키 공간만큼 큰 테이블이 필요하다는 뜻은 아니다.