CSED233 · 데이터구조 · 포스텍

정리본 1. Introduction

자료구조가 무엇인지, 왜 선택이 성능을 좌우하는지, 이 강의에서 무엇을 배우는지.

1. 자료구조(Data Structure)란?

자료구조(Data Structure): 데이터를 조직하고 효율적으로 관리하는 방법.

Program = Data Structure + Algorithm

프로그램이 느릴 때 원인은 두 가지 중 하나다. 나쁜 알고리즘이거나, 부적절한 자료구조거나. 그런데 실제로는 **부적절한 자료구조가 더 흔한 원인**이다.

- **Data Structure(자료구조)**는 "데이터를 어떻게 저장할 것인가"를 결정한다 → 메모리 구조, 연산 방식, 성능 특성.
- **Algorithm(알고리즘)**은 "데이터를 어떻게 처리할 것인가"를 결정한다 → 단계별 절차, 연산 조합, 최적화 방식.

둘은 독립적이지 않다. 자료구조는 알고리즘의 구현 방식과 연산 효율에 영향을 주지만, 사용할 수 있는 알고리즘을 하나로 결정하지는 않는다.

예제 · 자료구조가 알고리즘을 제한한다

같은 "정렬" 작업도 자료구조에 따라 선택지가 달라진다.

- **배열(Array)**: Bubble, Selection, Insertion, Merge, Quick, Heap — 6가지 이상 선택 가능.
- **연결 리스트(Linked List)**: Merge, Insertion만 효율적. Quick Sort도 구현할 수 있지만 Random Access가 O(n)이라 배열용 구현 그대로는 비효율적이다. 연결 리스트에는 Merge Sort가 적합하다 (최악 O(n log n) 보장).
- **Binary Search Tree(이진 탐색 트리)**: In-order Traversal(중위 순회)은 키를 오름차순으로 방문하는 것이지 트리를 정렬하는 연산은 아니다 (O(n)).

→ 올바른 자료구조 선택이 곧 올바른 알고리즘 선택이다.

2. 자료구조의 종류



이 강의에서 다루는 자료구조의 분류

2.1 선형 자료구조

배열(Array)

1	2	3	4	5

메모리 연속 할당 · Random Access O(1) ✓ · 크기 고정 ✗

연결 리스트(Linked List)



메모리 분산 할당 · 크기 유동적 ✓ · Random Access 불가 ✗

스택(Stack) — LIFO

5
4
3
2
1

← Pop / Push (한쪽 끝에서만)

큐(Queue) — FIFO

Front → ← Rear

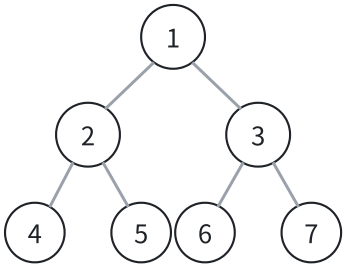
1	2	3	4	5

삽입은 Rear(뒤) · 삭제·처리는 Front(앞)에서

선형 자료구조 4종: 같은 1차원이지만 접근 방식이 다르다

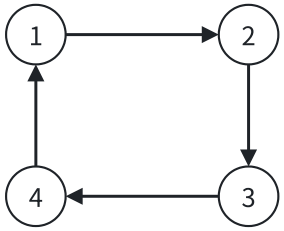
2.2 비선형 자료구조

트리(Tree) — 계층적



부모-자식 관계 · 순회 방식 다양 · 정렬 용도

그래프(Graph) — 복잡한 관계



Cycle(사이클) 가능 · 최단경로, 연결성 분석

해시 테이블(Hash Table)



Hash Function으로 Key → 인덱스 변환
평균 O(1) 검색 · 순서는 없음

비선형 자료구조 3종

3. 왜 중요한가: 100만 개 검색 실험

100만 개 데이터에서 특정 값 하나를 찾는다고 하자. 자료구조만 바꿨을 뿐인데 결과는 이렇게 갈린다 (연산당 1ns 가정).

자료구조	시간복잡도	실제 비교 횟수	소요 시간
배열 + 선형 탐색	O(n)	평균 500,000회	0.5ms
이진 탐색 트리(BST, 균형)	O(log n)	평균 20회	0.00002ms
해시 테이블	O(1)	평균 1회	0.000001ms

- 배열 vs BST → **25,000배** 차이, 배열 vs Hash → **500,000배** 차이.
- 작은 규모에서는 절대적인 경계가 없고 상수·구현 비용이 더 중요할 수 있지만, n이 커지면 O(n)과 O(log n) 검색 횟수 차이의 비율이 n/log n 형태로 커진다. 비율은 약 $n/(2\log_2 n)$으로, n = 100K에서 약 3,010배, n = 1M에서 약 25,086배이다.

같은 연산도 구조마다 비용이 다르다

"중간에 삽입" 한 번을 예로 들면:

- **배열**: 인덱스가 주어지면 접근 O(1) + 오른쪽 원소 Shift O(n) = O(n).

- **연결 리스트**: 위치까지 순회하면 O(n)이 들고, 직전 노드 포인터가 주어지면 삽입 자체는 O(1)이다. 연결 위치를 이미 알 때 배열보다 유리하다.
- **트리**에서 찾기: 미정렬 배열의 선형 탐색은 평균 O(n), 정렬 배열의 이진 탐색은 O(log n), 균형 BST는 O(log n), 일반 BST는 최악 O(n)이다. n = 1M 기준 미정렬 배열 평균 약 500,000회 vs 균형 BST 약 20회로 약 25,000배이다.

문제 해결 방식 자체가 자료구조에 의존한다.

4. 예제로 보는 선택의 차이: 성적 조회 시스템

요구사항: 학생 1000명, 학번을 입력하면 성적 반환. 같은 요구사항을 세 가지 자료구조로 설계해 보자.

방안 비교

방안	구조	검색 방식	평균 비교
A. 배열	[성적1][성적2]…[성적1000]	처음부터 끝까지 순서대로 비교	O(n) ≈ 500회
B. BST	중앙값 학번 500이 루트, 좌우로 분기 (균형 트리 가정)	크기 비교로 절반씩 제외	O(log n) ≈ 10회
C. 해시 테이블	Hash Function으로 학번 → 인덱스	계산 후 바로 접근	O(1) ≈ 1회

코드 예시

```
// A. 배열
for (i = 0; i < 1000; i++) if (id[i] == target) return score[i];

// B. BST
if (target < node.key) search(node.left); else search(node.right);

// C. 해시 테이블
return hashTable[hash(target)];
```

같은 문제인데 **500회 vs 10회 vs 1회** — 자료구조만으로 50배 이상 차이가 난다.

5. 어떤 자료구조를 고를까

정답이 하나로 정해진 것이 아니라, 문제의 조건을 보고 트레이드오프를 따지는 과정이다. 세 가지 질문을 순서대로 던지면 된다.

선택 기준 3단계

1. **가장 빈번한 연산이 무엇인가?**
   - 검색 위주 → Hash Table / BST (예: 전화번호부, 성적 조회)
   - 최대/최소가 자주 필요 → Heap (예: 작업 우선순위, CPU 스케줄링)
   - 삽입/삭제 + 순서 유지 → AVL Tree (예: 순위 변동, 실시간 업데이트). AVL이 유지하는 것은 키의 정렬 순서이다.
2. **메모리 제약이 있는가?**
   - 제한 있음 → 메모리 사용량을 따져 선택한다. 연결 리스트도 노드마다 포인터 오버헤드가 있어 메모리 제한만으로 연결 리스트를 고르지는 않는다 (hash table처럼 여유 bucket이 불필요하다는 점은 비교 요소. 예: 임베디드)
   - 충분함 → Hash Table (예: 클라우드, 고성능 서버)
3. **최악의 경우 보장이 중요한가?**
   - 중요(실시간) → Merge Sort의 최악 O(n log n) 보장 — 보통 O(n) 추가 공간이 필요하고, 실시간에서는 실제 시간 상한도 확인해야 한다 (예: 의료, 항공, 금융)
   - 평균만 중요 → Quick Sort 평균 O(n log n), 최악 $O(n^2)$ - 피벗·입력에 따라 달라짐 (예: 일반 데이터 처리)

5.1 연산별 성능 요약

자료구조	검색	삽입	삭제	순서 유지	사용 시기
배열	O(1) (인덱스 접근), 정렬 시 값 검색 O(log n)	O(n), 끝은 분할상환 O(1) (재할당 시 최악 O(n))	O(n), 끝은 O(1)	◯ (인덱스)	정렬된 고정 데이터

연결 리스트	O(n)	O(1) (위치 알 때)	O(1) (필요한 포인터를 알고 있을 때)	○ (순서)	크기가 자주 변할 때
BST	O(log n) 평균	O(log n) 평균	O(log n) 평균	○ (In-order)	검색 + 순서 유지
Hash Table	O(1) 평균	O(1) 평균	O(1) 평균	×	검색만 중요할 때
Heap	O(n)	O(log n)	O(log n) (루트 삭제 기준)	△ (부모-자식 부분 순서만)	우선순위 큐, Sort

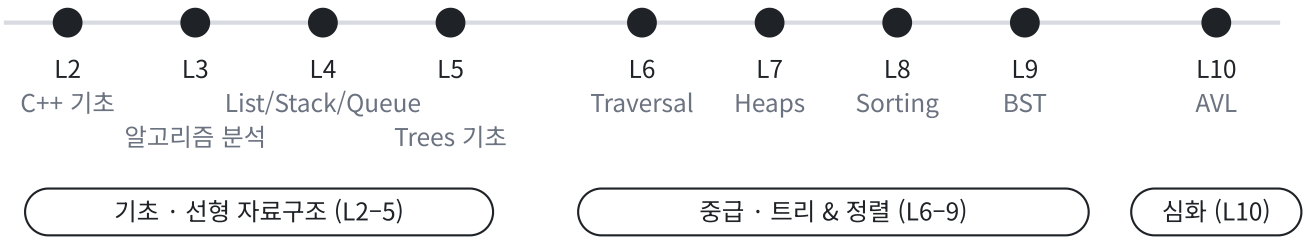
BST의 '평균'은 랜덤 삽입 순서의 기대값; 편향되면 최악 O(n). AVL Tree 등 균형 BST는 검색·삽입·삭제 O(log n) 보장.

5.2 n = 100만일 때 체감

자료구조	검색 1회	삽입 1회	체감
배열	평균 약 500,000회	중간 삽입 시 이동 평균 약 500,000개 (끝이면 1회)	매우 느림
연결 리스트	평균 약 500,000개 노드 방문	1회 (위치 알 때)	느림
BST (균형)	20회	20회	매우 빠름
해시 테이블	1회	1회	극도로 빠름

기준은 성공 검색 평균이다.

6. 강의 로드맵과 학습 전략



L2(C++)와 L3(알고리즘 분석)이 모든 것의 토대. L3, L8, L10에서 개념적 도약이 온다.

- **L2 C++ 기초**: 포인터, 동적 할당, 메모리 관리 — 자료구조 구현의 기초.
- **L3 알고리즘 분석**: Big-O 표기법, 시간/공간 복잡도 — 성능 평가의 기준.
- **L4–5**: 선형 자료구조 3종, 트리 기본 성질.
- **L6–9**: 순회와 트리 재구성, 우선순위 큐/힙, 정렬 5종, BST.
- **L10**: AVL Tree — Self-Balancing(자가 균형)과 Rotation(회전).

6.1 학습 목표 4단계

1. **개념 이해** — List, Stack, Queue, Tree가 무엇인지 정의를 안다.
2. **기본 연산 구현** — Insert, Delete, Search를 코드로 쓴다.
3. **성능 분석** — 각 연산의 시간/공간 복잡도를 Big-O로 계산한다.
4. **선택과 적용** — 주어진 문제에 어떤 자료구조를 쓸지, 왜 그것인지 설명한다. 이 강의의 최종 목표.

6.2 AI 활용 기준

- **허용**: 개념 질문("Stack이 뭐야?"), 구현 예시 요청, 강의 복습, 디버깅.
- **금지**: 시험 중 사용, AI가 쓴 코드 그대로 제출, 이해 없이 복사.
- "어떤 자료구조를 써야 하는가"를 판단하는 능력이 진짜 경쟁력이다.

7. Quiz

Q1. 같은 데이터로 배열과 BST를 구성했을 때, 검색 성능이 다른 이유는?

> 힌트

핵심은 "다음에 어디를 볼지 아는가"다. 배열은 원소의 위치 정보가 없어 처음부터 훑어야 하고, BST는 크기 비교 한 번으로 탐색 범위를 절반으로 줄인다.

> 정답

개념은 힌트 참고.

① 배열: target이 어디 있는지 알 수 없어 평균 n/2회 비교 → O(n).

② BST: 루트와 비교해 좌/우 하나를 버리는 것을 반복 → O(log n).

③ 같은 데이터인데 구조가 다르면 쓸 수 있는 탐색 절차가 달라진다.

정답: 자료구조가 연산 방식을 결정하기 때문 — 배열은 선형 탐색 O(n), BST는 이진 탐색 O(log n)이 가능하다.

Q2. "자료구조 선택이 알고리즘을 결정한다"는 무슨 의미인가?

> 힌트

섹션 1의 정렬 예시를 떠올려 보자. 배열에서는 6가지 정렬이 가능하지만 연결 리스트에서는 QuickSort가 Random Access 부재로 비효율적이고, BST는 순회만으로 정렬된다.

> 정답

개념은 힌트 참고.

① 배열 → Random Access 가능 → Bubble/Quick/Merge 등 대부분의 정렬 사용 가능.

② 연결 리스트 → Random Access 불가 → Merge, Insertion만 효율적.

③ BST → In-order Traversal 자체가 정렬 → 별도 알고리즘 불필요.

정답: 같은 문제라도 자료구조마다 필요한(가능한) 알고리즘이 다르다. 자료구조를 고르는 순간 알고리즘 후보가 정해진다는 뜻이다.

Q3. 왜 배열과 연결 리스트가 둘 다 필요한가? 연결 리스트가 더 나은가?

> 힌트

각각의 장점이 상충(trade-off)한다: Random Access O(1) ↔ 동적 크기.

> 정답

개념은 힌트 참고.

① Random Access가 필요하면 배열이 유리하다 — 인덱스 접근 O(1)이고, 동적 배열도 확장이 가능하다.

② 중간 삽입·삭제가 잦으면 연결 리스트가 유리할 수 있지만, 위치를 찾는 비용과 노드마다 붙는 포인터 오버헤드를 함께 따져야 한다.

③ 어느 한쪽이 모든 상황에서 우월하지 않다.

정답: 아니다. 둘은 트레이드오프 관계라 문제의 특성에 따라 골라야 한다.

Q4. 100만 개 데이터 검색에서 배열 vs BST 차이가 수만 배가 되는 이유는?

> 힌트

O(n)과 O(log n)에 n = 1,000,000을 대입해 보자. $\log_2(10^6) \approx 20$.

> 정답

개념은 힌트 참고.

① 배열 선형 탐색: 평균 n/2 = 500,000회 비교.

② BST 이진 탐색: $\log_2$(100만) ≈ 20회 비교.

③ 500,000 / 20 = 25,000 → 약 2만 5천 배 차이.

정답: O(n) = 50만 회 vs O(log n) = 20회. 데이터가 클수록 차이는 더 벌어지므로 빅데이터에서는 자료구조가 성능을 사실상 결정한다.

Q5. Hash Table이 검색 O(1)인데도 모든 곳에 쓰이지 않는 이유는?

> 힌트

O(1)의 대가를 생각해 보자: 해시 충돌(Collision), 순서 정보 소실, 메모리 오버헤드.

> **정답**

개념은 힌트 참고.

① Collision 처리 로직이 복잡하다.

② 데이터의 순서를 유지하지 못한다 → 순서가 필요하면 BST.

③ 메모리 오버헤드가 있다 → 메모리가 빠듯하면 배열.

정답: Collision 처리 비용, 순서 없음, 메모리 오버헤드 때문에 요구사항에 따라 BST나 배열이 더 나은 선택이 된다.